

**IML -EX1**  
**Amitay Sicherman -203449004**

Warm-up - Algebra Recap.....	2
SVD .....	4
Multivariate Calculus .....	7
Multivariate Gaussian- practical question .....	10
Concentration inequalities - practical question.....	14
Python Code.....	17

# Warm-up - Algebra Recap

1ste

: Vector  $u$  hat  $u$  hat

$$P = \|v\| \cos \theta \cdot \frac{u}{\|u\|} = \frac{\langle v, u \rangle}{\|u\|^2} \cdot u$$

$$= \frac{\langle \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 2 \end{pmatrix} \rangle}{\left\| \begin{pmatrix} 0 \\ -1 \\ 2 \end{pmatrix} \right\|^2} \cdot \begin{pmatrix} 0 \\ -1 \\ 2 \end{pmatrix}$$

$$= \frac{-2 + 3 + 6}{1 + 1 + 4} \cdot \begin{pmatrix} 0 \\ -1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ -\frac{3}{2} \\ \frac{3}{2} \end{pmatrix}$$

2ste

:  $u$  hat  $u$  hat  $u$  hat

$$\frac{\langle \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 2 \end{pmatrix} \rangle}{\left\| \begin{pmatrix} 0 \\ -1 \\ 2 \end{pmatrix} \right\|^2} \cdot \begin{pmatrix} 0 \\ -1 \\ 2 \end{pmatrix} = \frac{1 + 3 - 4}{1 + 1 + 1} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} = 0$$

שאלה 3

טכניקת יתר סטנדרטית:

ליתר  $\theta = \angle(w, v) < \frac{\pi}{2}$  כי הנורמה הנורמלית היא  $\frac{\pi}{2}$  -  
בתפוסת הנורמה כי

$$\langle w, v \rangle = \|w\| \cdot \|v\| \cdot \cos \theta$$

ובמקרה זה:

$$\langle w, v \rangle = \|w\| \cdot \|v\| \cdot \cos \theta = 0$$

מכאן  $\theta = \frac{\pi}{2}$  ויש להם וקטור הנורמלי - ואם הנורמה

הנורמה סקאלרית,  $\theta = \frac{\pi}{2}$  ויש להם וקטור הנורמלי

$$\cos \theta = 0 \Rightarrow \theta = \frac{\pi}{2}$$

נניח  $\theta = \frac{\pi}{2}$ :

יש להם  $\theta = \frac{\pi}{2}$ , אז נניח  $\theta = \frac{\pi}{2}$  וההנחה

$$\langle w, v \rangle = \|w\| \cdot \|v\| \cdot \cos \frac{\pi}{2} = 0$$

נניח

שאלה 4

$$\|Ax\|^2 = \langle Ax, Ax \rangle = (Ax)^T Ax$$

$$= x^T A^T A x = \|x\|_2^2 = \|x\|_2^2$$

$$\Rightarrow \|Ax\|_2 = \|x\|_2$$

# SVD

שאלה 5:

אשר 1:

היות מרחב הפנים (מרחב האנטיגראד) יכול להכיל

בבסיס יחידה

$$O = \text{diag}(a_1, \dots, a_n) \Rightarrow O^{-1} \in \text{diag}(\frac{1}{a_1}, \dots, \frac{1}{a_n})$$

אז היות שה  $O(n)$

אשר 2:

היות שאלו הסיבובים (אנטיגראד) יכולים להכיל

בבסיס יחידה -  $A = \text{orthogonal matrix}$

$$A \cdot A^{-1} = A \cdot A^T = I_n \Rightarrow A^{-1} = A^T$$

כאן היות  $A^T$  יכול להכיל  $O(n^2)$

$$A_{ij} = A_{ji} \quad \forall i, j \in \{1, \dots, n\}$$

הוכחה:

$$A = U \Sigma V^T \quad \text{SVD decomposition}$$

$$\Rightarrow A^{-1} = (U \Sigma V^T)^{-1} = (V^T)^{-1} \Sigma^{-1} U^{-1}$$

$$\begin{aligned} & \xrightarrow{\text{orthogonal}} \begin{aligned} & \xrightarrow{\text{orthogonal}} \end{aligned} \\ & = V \begin{pmatrix} \Sigma^{-1} & 0 \\ 0 & 0 \end{pmatrix} U^T \end{aligned}$$

היות שאלו הסיבובים

$$C \cdot C^T = \begin{bmatrix} 50 & 30 \\ 30 & 50 \end{bmatrix}$$

$$\begin{bmatrix} 0 & 6 \\ 6 & 0 \end{bmatrix}$$

(I)

$$A^{SVD} = U \Sigma U^T$$

אם  $\lambda$  הוא הערך העigen של  $A$  (II)

$$A^T A = U \Sigma \Sigma^T U^T$$

52

$$\begin{bmatrix} 50 & 30 \\ 30 & 50 \end{bmatrix} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} \lambda_1^2 & 0 \\ 0 & \lambda_2^2 \end{bmatrix} \begin{bmatrix} a & c \\ b & d \end{bmatrix} \quad (\text{Goal})$$

$$\begin{bmatrix} 50 & 30 \\ 30 & 50 \end{bmatrix} = \begin{bmatrix} a^2 \lambda_1^2 + c^2 \lambda_2^2 & a b \lambda_1^2 + c d \lambda_2^2 \\ c a \lambda_1^2 + d b \lambda_2^2 & a b \lambda_1^2 + c d \lambda_2^2 \end{bmatrix}$$

$$\Rightarrow \lambda_1^2 = 80, \lambda_2^2 = 20 \quad a = \frac{1}{\sqrt{2}}, c = -\frac{1}{\sqrt{2}}$$

$$U = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \quad a = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \quad \text{זוהי}$$

$$C^T C = U \Sigma \Sigma^T U^T \quad \text{על כן  $U$  הוא} \quad (\text{III})$$

$$C^T C = U \Sigma \Sigma^T U^T = U U$$


$$U^T = \begin{pmatrix} \sqrt{\frac{1}{10}} & \sqrt{\frac{9}{10}} \\ \sqrt{\frac{9}{10}} & -\sqrt{\frac{1}{10}} \end{pmatrix}$$

p11

3.1.1e

$$b_0 = \sum_{i=0}^n a_i V_i$$

if  $V_i$  are orthonormal



$$A^* b_0 = \sum_{i=1}^n a_i A^* V_i$$

1.1.1

$$= \sum_{i=1}^n a_i \hat{a}_i^* V_i$$

$$= \hat{a}_1^* \sum_{i=1}^n \left( \frac{\hat{a}_i^*}{\hat{a}_1^*} \right) V_i$$

$$= \hat{a}_1^* \sum_{i=1}^n \left( \frac{\hat{a}_i^*}{\hat{a}_1^*} \right) V_i$$

if  $V_i$  are orthonormal



$V_i$  are orthonormal



## Multivariate Calculus

על פני

המשפט הבא מתאר את המרחב המרובע של המרחב המרובע (המרחב המרובע)

$$f(\vec{x}) = \sum_{i=1}^n \sigma_i u_i u_i^T \vec{x} \quad \left| \quad \begin{array}{l} u_i \text{ הוא המרחב} \\ \sigma_i > 0 \end{array} \right.$$

$$f(\vec{x})_j = \left( \sum_{i=1}^n \sigma_i u_i u_i^T \vec{x} \right)_j$$

ובכן

אבל

אם נחשב את המרחב:

$$\frac{\partial f(\vec{x})_j}{\partial \sigma_k} = \frac{\partial}{\partial \sigma_k} \left( \sum_{i=1}^n \sigma_i u_i u_i^T \vec{x} \right)_j$$

המשפט הבא מתאר את המרחב המרובע של המרחב המרובע (המרחב המרובע) עבור  $k=j$  נקבל  $\frac{\partial f(\vec{x})_j}{\partial \sigma_j} = 1$  וזהו המרחב המרובע של המרחב המרובע (המרחב המרובע).

$$\frac{\partial f(\vec{x})_j}{\partial \sigma_k} = \left( \sum_{i=1}^n u_i u_i^T \vec{x} \right)_j$$

אם נחשב את המרחב המרובע של המרחב המרובע (המרחב המרובע) עבור  $k \neq j$  נקבל  $\frac{\partial f(\vec{x})_j}{\partial \sigma_k} = 0$  וזהו המרחב המרובע של המרחב המרובע (המרחב המרובע).

$$J_{\text{all}}(f) = U \text{diag}(U^T \vec{x})$$

log 1.8

imble (1.8) (1.8)

1.8

$$x = f(w) - y$$

$$y = \frac{1}{2} \|x\|^2$$

1.8

$$h = \frac{1}{2} \|x(w)\|^2$$

$$\nabla h = \frac{\partial}{\partial x} \left( \frac{1}{2} \|x(w)\|^2 \right) \cdot \frac{\partial x(w)}{\partial w}$$

~~1.8~~

$$= (w) \cdot (f(w) - y)^T \cdot \nabla f(w)$$




עלה 10

$$g(s)_j = \frac{e^{s_j}}{\sum_i e^{s_i}}$$

$$\frac{\partial g_i}{\partial s_j} = \frac{\partial}{\partial s_j} \left( \frac{e^{s_i}}{\sum_k e^{s_k}} \right)$$

נבדוק את כל המקרים:

$$= \left( \sum_k e^{s_k} \right)^{-2} \cdot \left( \frac{\partial}{\partial s_j} e^{s_i} - e^{s_i} \cdot \frac{\partial}{\partial s_j} \sum_k e^{s_k} \right)$$



$$\text{if } i=j: \Rightarrow \left( \sum_k e^{s_k} \right)^{-2} \cdot (e^{s_i} - e^{s_i} \cdot e^{s_i})$$

$$= g(s)_i (1 - g(s)_i)$$

$$\text{if } i \neq j: \Rightarrow \left( \sum_k e^{s_k} \right)^{-2} (0 + e^{s_i} e^{s_j})$$


$$= g(s)_i \cdot g(s)_j$$

$$\frac{\partial g_i}{\partial s_j} = g(s)_i (\delta_{ij} - g(s)_j)$$


הסימנים למעלה הם:  $\delta_{ij}$  וקבוצה

## Multivariate Gaussian- practical question

שאלה 11:



שאלה 12:



מטריצת ה COV


$\begin{bmatrix} 0.01 & 0 & 0 \end{bmatrix}$

$\begin{bmatrix} 0 & 0.25 & 0 \end{bmatrix}$

[0. 0. 4. ]]

ניתן לראות כי עדיין אין קורלציה בין הצירים (רק האיברים על האלכסון קיימים) אבל יש מתיחה – כמו שניתן לראות בסרטוט. יש מתיחה אבל אין סיבוב. עדיין מקביל לצירים.

**שאלה 13:**



מטריצת הCOV:

[[0.2012325 0.77954016 0.22139559]


[0.77954016 3.38267323 1.18514263]

[0.22139559 1.18514263 0.67609427]]

המטריצה לא אלכסונית- יש גם מתיחה וגם סיבוב (כמו שרואים בסרטוט)

**שאלה 14:**


נעריך כי הסרטוט יראה כמו גאוסיאן דו מימד סביב אותם ערכים, וזה אכן מה שקיבלנו:



**שאלה 15:**

נצפה לראות גאוסיאן בעל אותם ערכים, אבל בצפיפות נמוכה יותר. כלומר צפיפות הנקודות דלילה יותר אבל


הצורה והערכים זהים- וזה אכן מה שקיבלנו:



## Concentration inequalities - practical question

שאלה 16 A:

נצפה לראות ככל ש  $M$  גדל, שאיפה אסימפטוטית לממוצע האמיתי (אשר מוערך להיות 0.25)

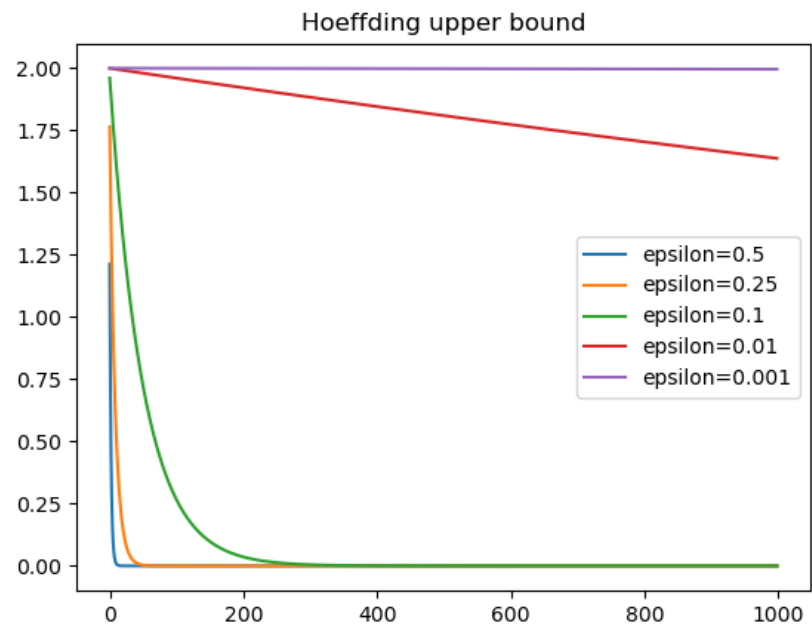
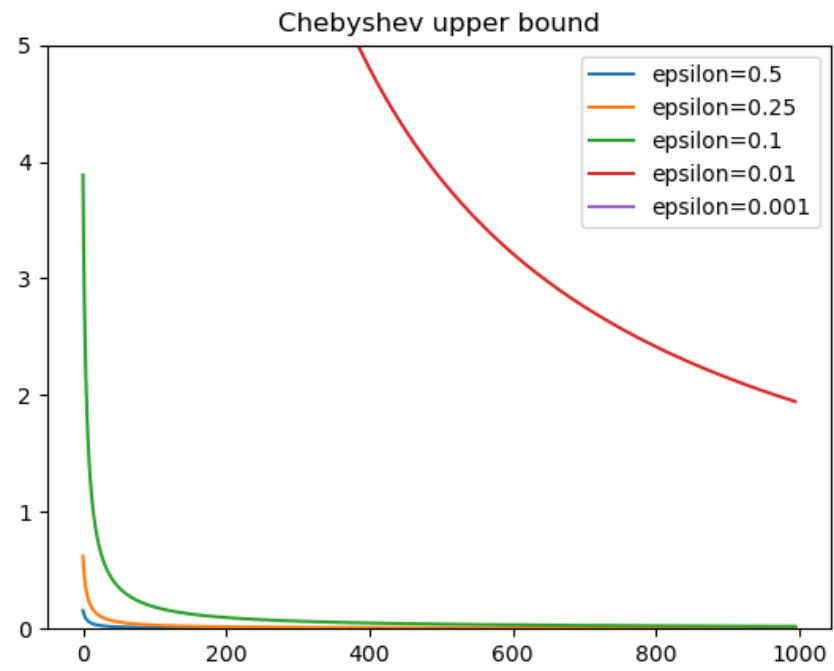


ניתן לראות כי כל השורות מתכנסות לערך מסוים ושכל הערכים הם "קרובים" לערך שציפינו לראות. כולם מתכנסים לאזור 0.25 ("מתקרבים" זה לא מוגדר – ובהמשך השאלה נדייק יותר)

שאלה 16 B:


\* בגרף הראשון חתכתי את ציר ה  $\gamma$  בנקודה 5 כאשר הקו הסגול מעליה על מנת לקבל גרף ברור יותר





שאלה C16:

נצפה לראות שככל ש  $M$  גדל נשאף למאה אחוז (1) – כאשר ככל שאפסילון גדול יותר נשאף מהר יותר



וזה אכן מה שקיבלנו- כאשר בעבור אפסילון קטן מאוד מספר הדגימות לא מספיק

## Python Code

# Python CODE

```
def conditional(x_y_z):
    temp=x_y_z[0:2,:]
    temp2=x_y_z[2,:]
    # cond=temp2>-0.4 and temp2<0.1
    return temp[:,np.logical_and(temp2>-0.4 , temp2<0.1)]

if __name__ == "__main__":
    mean = [0, 0, 0]
    cov = np.eye(3)
    x_y_z = np.random.multivariate_normal(mean, cov, 50000).T
    # plot_3d(x_y_z);
    s=np.diag([0.1,0.5,2])
    newData=np.matmul(s,x_y_z)
    newCov=np.matmul(np.matmul(s,cov),s.transpose())
    print("scale cove:")
    print(newCov)
    # plot_3d(newData)
    ortoM=get_orthogonal_matrix(3)
    ortoData=np.matmul(ortoM,newData)
    # plot_3d(ortoData)
    print("orto cove:")
    print(np.matmul(np.matmul(ortoM,newCov),ortoM.transpose()))

    # plot_2d(x_y_z[0:2,:])
    # plot_2d(newData[0:2,:])
    # plot_2d(ortoData[0:2,:])

    plot_2d(conditional(x_y_z))
    plot_2d(conditional(newData))
    plot_2d(conditional(ortoData))
```

```
import numpy as np
import matplotlib.pyplot as plt
import math
row=1000
col=100000
data = np.random.binomial(1, 0.25, (col,row))
epsilons=(0.5, 0.25, 0.1, 0.01, 0.001)

# part a:
av=np.zeros(row)
for i in range(5):
```

```

        for m in range(1,row):
            av[m]=np.mean(data[i,1:m])
        plt.plot(av)
plt.show()

# part b:
# Chebyshev
i=1
upperBoundChebyshev=np.zeros(row)
fig = plt.figure()
ax = fig.add_subplot(111)

for epsilon in epsilons:
    var=np.var(data[i,:])
    for m in range(1,row):

        upperBoundChebyshev[m]=var/(m*epsilon*epsilon)
        plt.plot(upperBoundChebyshev[5:],label='epsilon='+str(epsilon))
legend = ax.legend()
plt.ylim([0,5])
plt.title("Chebyshev upper bound")

plt.show()

# Hoeffding
i=1
upperBoundHoeffding=np.zeros(row)
fig = plt.figure()
ax = fig.add_subplot(111)

for epsilon in epsilons:
    var=np.var(data[i,:])
    for m in range(1,row):

        upperBoundHoeffding[m]=2*math.exp(-2*m*epsilon*epsilon)

        plt.plot(upperBoundHoeffding[1:],label='epsilon='+str(epsilon))
legend = ax.legend()
plt.title("Hoeffding upper bound")
plt.show()

# part c
fig = plt.figure()
ax = fig.add_subplot(111)
pres=np.zeros(row)
for epsilon in epsilons:
    print(epsilon)
    for m in range(1,row):
        temp=np.mean(data[:,0:m],axis=1)
        pres[m]=(col-np.count_nonzero(temp > 0.25+epsilon) -np.count_nonzero(temp
< 0.25-epsilon))/col
    plt.plot(pres[1:],label='epsilon='+str(epsilon))

```

```
legend = ax.legend()  
plt.title("16 C")  
  
plt.show()
```