

IML -EX1
Amitay Sicherman -203449004

Warm-up - Algebra Recap	2
Q1:.....	2
Q2:.....	2
Q3:.....	2
Q4:.....	2
SVD	3
Q5:.....	3
Q6:.....	3
Q7:.....	4
Multivariate Calculus	6
Q8.....	6
Q9.....	7
Q10.....	7
Multivariate Gaussian- practical question	9
Q11.....	9
Q12.....	9
Q13.....	10
Q14.....	10
Q15.....	11
Concentration inequalities - practical question.....	13
Q16.....	13

Warm-up - Algebra Recap

Q1:

We use that

$$P_v u = \frac{\langle v, u \rangle}{|u|^2} \vec{u}$$

Calculate:

$$P_v u = \frac{\left\langle \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix}, \begin{pmatrix} 0 \\ -1 \\ 1 \\ 2 \end{pmatrix} \right\rangle}{\left\| \begin{pmatrix} 0 \\ -1 \\ 1 \\ 2 \end{pmatrix} \right\|^2} \cdot \begin{pmatrix} 0 \\ -1 \\ 1 \\ 2 \end{pmatrix} = \frac{9}{6} \cdot \begin{pmatrix} 0 \\ -1 \\ 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ -\frac{3}{2} \\ 3 \\ 3 \end{pmatrix}$$

Q2:

Use the same equation,

Calculate:

$$P_v u = \frac{\left\langle \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 1 \\ -1 \end{pmatrix} \right\rangle}{\left\| \begin{pmatrix} 1 \\ 0 \\ 1 \\ -1 \end{pmatrix} \right\|^2} \cdot \begin{pmatrix} 1 \\ 0 \\ 1 \\ -1 \end{pmatrix} = \frac{0}{3} \cdot \begin{pmatrix} 1 \\ 0 \\ 1 \\ -1 \end{pmatrix} = 0$$

Q3:

we use the definition of $\langle v, u \rangle$:

$$\langle v, u \rangle = |u| \cdot |v| \cdot \cos(\theta)$$

we will prove the two sides:

$$\text{First side, } \theta = \pm 90 \rightarrow \cos(\theta) = 0 \rightarrow |u| \cdot |v| \cdot \cos(\theta) = 0 \rightarrow \langle v, u \rangle = 0$$

$$\text{second side: } \langle v, u \rangle = 0 \rightarrow |u| \cdot |v| \cdot \cos(\theta) = 0 \xrightarrow[|u|, |v| > 0]{\Rightarrow} \cos(\theta) = 0 \rightarrow \theta = \pm 90$$

Q4:

we use that:

1. for vector v : $\|v\|_2 = \sqrt{\sum v_i^2} = \sqrt{v \cdot v}$
2. for orthogonal matrix A : $AA^T = AA^{-1} = I$

And now we prove:

$$\|Ax\|_2^2 = Ax(Ax)^T = Ax A^T x^T = A A^T x x^T = x x^T = \|x\|_2^2$$

SVD

Q5:

we use :

1. for diagonal matrix $D^{n \times n} = d_{ij}$

: calculate the inverse matrix of D can be made in $O(n)$ by $D^{-1} = \frac{1}{d_{ij}}$

2. for orthogonal matrix A :: calculate the inverse matrix of D can be made in $O(n^2)$ by $A^{-1} = A^T$

proof:

$$\begin{aligned} A &= UDV^T \\ \rightarrow A^{-1} &= (V^T)^{-1} D^{-1} U^{-1} \\ \text{from 2} &\rightarrow \boxed{(VD^{-1}U^T)} \end{aligned}$$

from (1) we can calculate D^{-1} in $O(n)$, from (2) we can calculate U, V transpose in $O(n^2)$ so the operation is more useful than the regular way that takes $O(n^{2.8})$

Q6:

Calculate:

$$c \cdot c^T = \begin{pmatrix} 50 & 30 \\ 30 & 50 \end{pmatrix}$$

We see that:

if $c = UDV^T$ if SVD so $cc^T = UDD^T U^T$ is EVD

so let say that $U = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ and $DD^T = \text{diag}(d1, d2)$

calculate:

$$DD^T = \text{diag}(d1^2, d2^2)$$

$$\begin{pmatrix} 50 & 30 \\ 30 & 50 \end{pmatrix} = \begin{pmatrix} a^2 d1^2 + cbd2^2 & abd1^2 + dbd2^2 \\ cad1^2 + dcd2^2 & abd1^2 + dbd2^2 \end{pmatrix}$$

And the solve is :

$$d1^2 = 80, d2^2 = 20, a = b = c = -d = \frac{1}{\sqrt{2}}$$

$$\rightarrow D = \begin{pmatrix} \sqrt{80} & 0 \\ 0 & \sqrt{20} \end{pmatrix}, U = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$$

Now, $c = UDV^T$ multiplate two sides with V in the right we get $cV = UDV^T V = UD$, multiplate two

sides in $c^{-1} = \begin{pmatrix} \frac{7}{40} & -\frac{1}{8} \\ \frac{1}{40} & \frac{1}{8} \end{pmatrix}$ in the left we get $c^{-1}cV = V = c^{-1}UD$

set the values of $c^{-1}UD$ and calculate the multiplate we get :


$$V = \begin{pmatrix} \sqrt{\frac{1}{10}} & \sqrt{\frac{9}{10}} \\ \sqrt{\frac{9}{10}} & -\sqrt{\frac{1}{10}} \end{pmatrix}$$

Q7:

3.1.1e

$$b_0 = \sum_{i=0}^n a_i V_i$$

if V_i are orthonormal



$$A^* b_0 = \sum_{i=1}^n a_i A^* V_i$$

1.1.1

$$= \sum_{i=1}^n a_i \hat{a}_i^* V_i$$

$$= \sum_{i=1}^n a_i \hat{a}_i^* V_i$$

$$= a_1 \hat{a}_1^* \sum_{i=1}^n \left(\frac{a_i \hat{a}_i^*}{a_1 \hat{a}_1^*} \right) V_i$$

if V_i are orthonormal



V_i are orthonormal

Multivariate Calculus

Q8

שאלה 8:

נתון וקטור \bar{x} המורכב מ- n כנסים (בסדר הולכי ירידה) וקטור \bar{u} המורכב מ- n וקטורים u_i וקטור $\bar{\sigma}$ המורכב מ- n סקלרים σ_i .

$$f(\bar{u}) = \sum_{i=1}^n \sigma_i u_i u_i^T \bar{x} \quad \left| \begin{array}{l} u_i \text{ הוא וקטור} \\ n \times 1 \end{array} \right.$$

$$f(\bar{u})_j = \left(\sum_{i=1}^n \sigma_i u_i u_i^T \bar{x} \right)_j \quad \text{זוהי}$$

אנחנו רוצים למצוא את הנגזרת:

$$\frac{\partial f(\bar{u})_j}{\partial \sigma_k} = \frac{\partial}{\partial \sigma_k} \left(\sum_{i=1}^n \sigma_i u_i u_i^T \bar{x} \right)_j$$

הנגזרת היא כזו שמתקבלת כאשר $k=j$ נקבל $\frac{\partial f(\bar{u})_j}{\partial \sigma_k} = 1$ וזוהי הנגזרת של f ביחס ל- σ_k כאשר $k=j$.

$$\boxed{\frac{\partial f(\bar{u})_j}{\partial \sigma_k} = \left(\sum_{i=1}^n u_i u_i^T \bar{x} \right)_j}$$

אם $k \neq j$ אז הנגזרת היא 0. זהו המצב הכללי.

$$u_k u_k^T \bar{x}$$

$$\boxed{J_{df} = U \text{diag}(U^T \bar{x})}$$

Q9

Q9

:מהלך (הוא) (הוא)
רצוי

$$x = f(\omega) - y$$
$$y = \frac{1}{2} \|x\|^2$$

/m

$$h = \frac{1}{2} \|x(\omega)\|^2$$
$$\nabla h = \frac{\partial}{\partial x} \left(\frac{1}{2} \|x(\omega)\|^2 \right) \cdot \frac{\partial x(\omega)}{\partial \omega}$$
$$= \omega \cdot (f(\omega) - y)^T \cdot \nabla f(\omega)$$

Q10


עלה 10

$$g(s)_j = \frac{e^{s_j}}{\sum_i e^{s_i}}$$

$$\frac{\partial g_i}{\partial s_j} = \frac{\partial}{\partial s_j} \left(\frac{e^{s_i}}{\sum_k e^{s_k}} \right)$$

נבדוק את כל המקרים:

$$= \left(\sum_k e^{s_k} \right)^{-2} \cdot \left(\frac{\partial}{\partial s_j} e^{s_i} - e^{s_i} \cdot \frac{\partial}{\partial s_j} \sum_k e^{s_k} \right)$$



$$\text{if } i=j: \Rightarrow \left(\sum_k e^{s_k} \right)^{-2} \cdot (e^{s_i} - e^{s_i} \cdot e^{s_i})$$

$$= g(s)_i (1 - g(s)_i)$$

$$\text{if } i \neq j: \Rightarrow \left(\sum_k e^{s_k} \right)^{-2} (0 + e^{s_i} e^{s_j})$$

$$= g(s)_i \cdot g(s)_j$$


$$\frac{\partial g_i}{\partial s_j} = g(s)_i (\delta_{ij} - g(s)_j)$$

הסימנים למעלה הם: δ_{ij} וקבוצה

Multivariate Gaussian- practical question


Q11

3D gaussian



Q12

Scale 3D gaussian



מטריצת ה COV

$\begin{bmatrix} 0.01 & 0 & 0 \end{bmatrix}$


$\begin{bmatrix} 0 & 0.25 & 0 \end{bmatrix}$

$\begin{bmatrix} 0 & 0 & 4 \end{bmatrix}$

ניתן לראות כי עדיין אין קורלציה בין הצירים (רק האיברים על האלכסון קיימים) אבל יש מתיחה – כמו שניתן לראות בסרטוט. יש מתיחה אבל אין סיבוב. עדיין מקביל לצירים.

Q13

Scale and rotate 3D gaussian



מטריצת הCOV:

$\begin{bmatrix} 0.2012325 & 0.77954016 & 0.22139559 \end{bmatrix}$

$\begin{bmatrix} 0.77954016 & 3.38267323 & 1.18514263 \end{bmatrix}$


$\begin{bmatrix} 0.22139559 & 1.18514263 & 0.67609427 \end{bmatrix}$

המטריצה לא אלכסונית- יש גם מתיחה וגם סיבוב (כמו שרואים בסרטוט), אבל היא סימטרית

Q14

נעריך כי הסרטוט יראה כמו גאוסיאן דו מימד סביב אותם ערכים, וזה אכן מה שקיבלנו:


marginal distribution- 2D gaussian



Q15

נצפה לראות גאוסיאן בעל אותם ערכים, אבל בצפיפות נמוכה יותר. כלומר צפיפות הנקודות דלילה יותר אבל הצורה והערכים זהים- וזה אכן מה שקיבלנו:

marginal distribution and conditional distribution - 2D gaussian




Concentration inequalities - practical question

Q16

שאלה 16 A:

נצפה לראות ככל ש M גדל, שאיפה אסימפטוטית לממוצע האמיתי (אשר מוערך להיות 0.25)


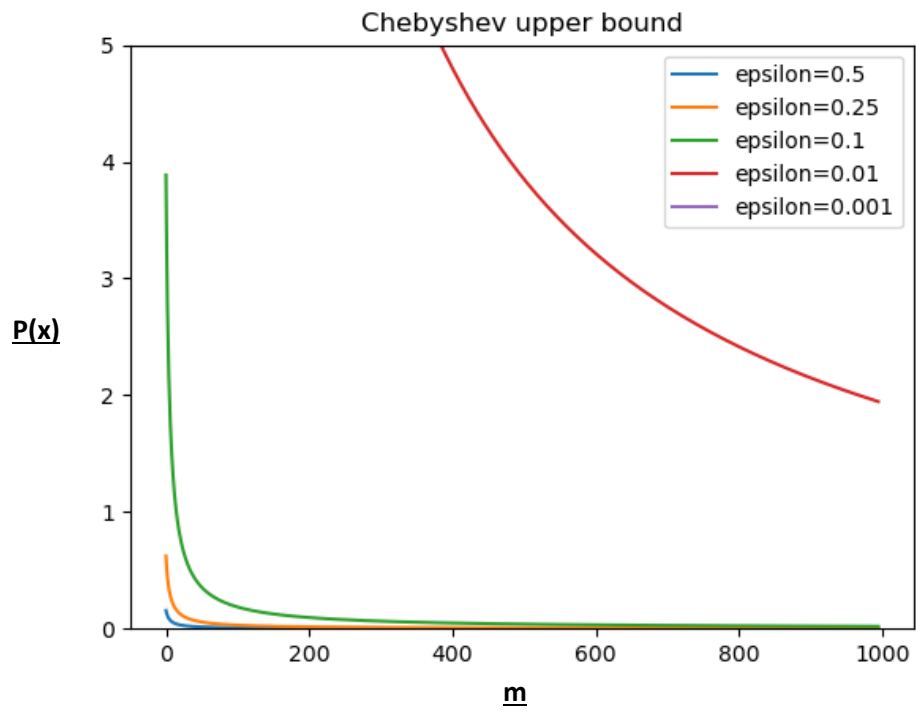
Estimate Everage of X



ניתן לראות כי כל השורות מתכנסות לערך מסוים ושכל הערכים הם "קרובים" לערך שציפינו לראות. כולם מתכנסים לאזור 0.25 ("מתקרבים" זה לא מוגדר – ובהמשך השאלה נדייק יותר)

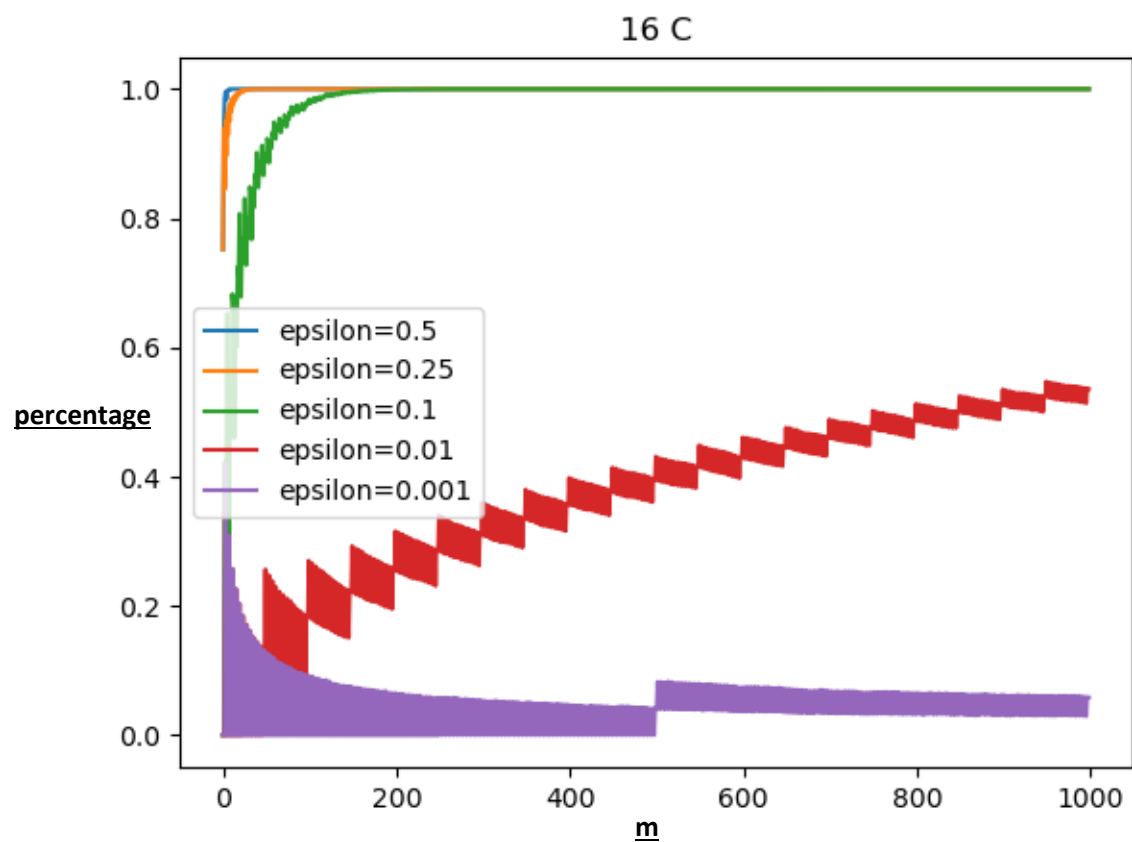
שאלה 16 B:

* בגרף הראשון חתכתי את ציר ה γ בנקודה 5 כאשר הקו הסגול מעליה על מנת לקבל גרף ברור יותר (כאשר באופן אמיתי אין משמעות לערכים ג



שאלה C16:

נצפה לראות שככל ש M גדל נשאף למאה אחוז (1) – כאשר ככל שאפסילון גדול יותר נשאף מהר יותר



וזה אכן מה שקיבלנו- כאשר בעבור אפסילון קטן מאוד מספר הדגימות לא מספיק- המודל עדיין לא מייצג כראוי את ההתפלגות ממנה לקחנו את הנתונים